

## Virtual Machines

### 2026 Modernized Edition | Module 03: Virtual Machines (Compute Engine VM)

Compute Engine 가상 머신(VM) 인스턴스, 2026 머신 패밀리(C3/C4/N4), 블록 스토리지, 무중단 Live Migration 및 Spot VM 종합 가이드

Google Cloud 교육 자료 | 베스핀글로벌 2026 개정판

## 모듈 03 학습 목차 (Agenda)

- 01 Compute Engine 옵션 & 머신 시리즈** | VM 개념 및 2026 최신 C3/C4/N4/A3 머신 타입 사양
- 02 가상 머신 접근 및 수명주기** | SSH/RDP 접속, IAM 역할 제어 및 인스턴스 생애주기
- 03 Compute Engine 스토리지 옵션** | Persistent Disk, Hyperdisk, Local SSD, Cloud Storage
- 04 무중단 실시간 이동 (Live Migration)** | 물리 서버 점검 시 무중단 VM 자동 실시간 이동 프로세스
- 05 Spot VM & 할인 요금제 (Cost FinOps)** | Spot VM (최대 90% 할인), 지속 할인(SUD) 및 약정 할인(CUD)
- 06 가상 머신 구축 및 실습** | Compute Engine VM 생성, 커스텀 사양 구성 및 SSH 접속 실습

SECTION 01

# 01

## Compute Engine 옵션 & 머신 시리즈


Google Cloud Compute Engine 가상 머신의 핵심 개념과 2026 최신 머신 패밀리(범용, 컴퓨팅, 메모리, GPU 가속기) 분류 및 커스텀 사양 구성 가이드

## Google Cloud 컴퓨팅 및 처리 옵션 비교 (Compute Options)

| 구분    | Compute Engine | GKE           | App Engine                  | Cloud Functions       | Cloud Run        |
|-------|----------------|---------------|-----------------------------|-----------------------|------------------|
| 언어 지원 | 모든 OS 및 언어     | 모든 컨테이너       | Python, Java, Go, Node.js 등 | Node.js, Python, Go 등 | 모든 컨테이너 (Docker) |
| 사용 모델 | IaaS (가상 머신)   | IaaS / PaaS   | PaaS (웹 앱)                  | Serverless FaaS       | Serverless PaaS  |
| 확장 방식 | MIG 자동 확장      | Pod / Node 확장 | 관리형 자동 확장                   | 이벤트 0→N 확장            | HTTP 0→N 확장      |
| 주요 사례 | 일반 OS 워크로드     | 컨테이너 클러스터     | 확장형 웹 애플리케이션                | 이벤트 기반 백엔드            | 컨테이너화 앱 서버리스 배포  |

## Compute Engine: Infrastructure as a Service (IaaS)

- 사전 정의된 머신 유형 및 커스텀 머신 유형:
  - 요구사항에 맞는 vCPU(코어) 및 메모리(RAM) 맞춤 조립
- 유연한 독립 스토리지 옵션 (2026 Modernized):
  - 영구 디스크 (Persistent Disk): Standard, Balanced PD (균형 성능), SSD, Extreme PD
  - 차세대 Hyperdisk: IOPS 및 스루풋 독립 동적 제어
  - Local SSD: 물리 서버 직접 탑재 초고속 NVMe 캐시
  - Cloud Storage: 대용량 오브젝트 스토리지 버킷 연동
- 글로벌 네트워킹 & OS 지원: Linux 및 Windows Server 지원



IaaS Architecture

# Compute Engine의 특징 (Features of Compute Engine)

## ⚙️ 머신 크기를 알맞게 조정

- 추천 엔진을 통한 최적의 머신 크기
- Cloud Monitoring 통계 기반 분석
- VM 생성 또는 크기 조정 후 24시간 뒤에 새로운 추천 제공

## 🌐 전역 부하 분산

- 고가용성을 위한 멀티 리전 전역 부하 분산 연동

## 🛡️ OS 패치 관리

- 패치 승인 만들기
- 유연한 예약 설정
- 고급 패치 구성 설정 적용

## 🔧 인스턴스 자동화 & 메타데이터

- 인스턴스 메타데이터 활용
- 시작 및 종료 스크립트 자동 실행

## 🛡️ 가용성 정책 (Availability)

- 라이브 마이그레이션 (Live Migration)
- 자동 다시 시작 (Automatic Restart)

## 💰 유연한 비용 모델

- 초당 청구 (Per-second Billing)
- 지속 사용 할인 (SUD)
- 약정 사용 할인 (CUD)

## ⚡ 선점형 VM 및 스팟 VM (Spot VMs)

- 최대 91% 비용 할인 혜택
- SLA 없음 (배치 워크로드 및 백그라운드 처리 적합)

## Compute Engine 하드웨어 연산 옵션 (CPU vs GPU)

### CPU (중앙 처리 장치)

- **Central Processing Unit:** 모든 일반 범용 워크로드, OS 제어 및 기본 서비스 프로세스 수행
- **범용 최적화:** 웹 서버, 애플리케이션 백엔드 및 일반 DB 시스템 운영에 필수

### GPU (그래픽 처리 장치)

- **Graphics Processing Unit:** 대규모 수평 병렬 연산 및 딥러닝 가속
- **2026 최신 GPU 지원:** NVIDIA H100, A100, L40S, T4 가속기 연동 (AI/ML 및 3D 렌더링)

## Tensor Processing Unit (TPU): Google 전용 AI 가속 하드웨어


- **Tensor Processing Unit (TPU):** Google이 자체 설계한 AI/ML 전용 도메인 특화 하드웨어 (ASIC)
- **더 높은 에너지 효율 및 성능 제공:** 대규모 행렬 연산(Matrix Multiplication) 처리에 특화
- **2026 Cloud TPU v5p & v5e 지원:**
  - 초대형 언어 모델 (LLM) 훈련 및 멀티모달 AI 추론 속도 극대화
  - H100 GPU 대비 최고의 비용 대비 성능 및 클러스터 확장성 제공



Cloud TPU

## Compute Engine 컴퓨팅 성능 및 vCPU / 메모리 구조

- vCPU의 표준 정의:
  - 1개의 vCPU는 물리 CPU의 1개 하드웨어 하이퍼스레드(Hyper-thread)와 1:1 대응
- vCPU 비례 네트워크 대역폭 확장:
  - 네트워크 처리량은 vCPU당 2Gbps씩 비례 확장 (일부 머신 예외 적용)
- 유연한 메모리 (RAM) 구성:
  - vCPU 사양에 맞춘 독립적인 대용량 RAM 메모리 확장 배치



vCPU & Network



RAM Memory

**vCPU & RAM Architecture**

## Compute Engine 디스크 스토리지 및 동적 확장


- 다양한 블록 스토리지 디스크 라인업:
  - 표준 영구 디스크 (Standard PD)
  - 균형 영구 디스크 (Balanced PD)
  - SSD 영구 디스크 (SSD PD / Extreme PD)
  - 초고속 로컬 SSD (Local SSD) 및 Hyperdisk
- 용량 비례 성능 확장: 표준 및 SSD PD는 할당된 각 GB 공간만큼 IOPS 및 스루풋 성능이 비례하여 확장
- 무중단 동적 디스크 확장 (No Downtime): VM 인스턴스 서비스 중단(다운타임) 없이 디스크 크기를 온라인 조절하거나 인스턴스 마이그레이션 가능



**Disk Dynamic Scaling**

## Compute Engine 강력한 네트워킹 기능 (Networking Features)

- 자동 및 커스텀 VPC 네트워크: 서브넷 자동 구성 및 사용자 맞춤 IP 설계
- 인바운드 / 아웃바운드 방화벽 규칙:
  - IP CIDR 대역 기반 액세스 제어
  - 인스턴스 및 그룹 네트워크 태그 기반 보안 정책 지정
- 고성능 부하 분산 (Load Balancing):
  - 리전별 HTTPS 부하 분산 서비스
  - 가동 준비(Warm-up) 과정이 필요 없는 초고속 네트워크 부하 분산(NLB)
- 전역 및 멀티 리전 서브네트워크: 구글 글로벌 사설 백본망 연동



Network Architecture

## 가상 머신(VM) 접속 및 액세스 방법 (Linux SSH vs Windows RDP)

| 구분        | Linux VM 접속 (SSH)                                 | Windows VM 접속 (RDP)                        |
|-----------|---------------------------------------------------|--------------------------------------------|
| 접속 도구     | Google Cloud 콘솔 브라우저 SSH, Cloud Shell, gcloud SDK | RDP 클라이언트 (Remote Desktop), PowerShell 터미널 |
| 키 / 인증 지정 | 컴퓨터 또는 서드 파티 클라이언트에서 SSH 키 쌍 생성 지정                | Windows 관리자 암호 (Password) 초기화 설정 필수        |
| 방화벽 허용 포트 | <b>tcp:22 (SSH)</b> 허용 방화벽 규칙 필요                  | <b>tcp:3389 (RDP)</b> 허용 방화벽 규칙 필요         |

## Compute Engine 가상 머신 수명 주기 (VM Lifecycle)

- 생성 및 시작 상태:
  - `PROVISIONING` → `STAGING` → `RUNNING` (실행 중)
  - `instances.start()` 호출로 다시 시작
- 정지 및 일시 중지 상태:
  - `instances.suspend()` → `SUSPENDED` (메모리 보관)
  - `instances.resume()` → `RUNNING` (즉시 재개)
- 중지 및 삭제 상태:
  - `instances.stop()` → `STOPPING` → `TERMINATED` (종료됨)
  - `instances.delete()` → 영구 삭제

 VM Lifecycle Diagram

**VM Lifecycle States**

## 실행 중인 VM의 상태 변경 비교 (State Changes & ACPI)

| 작업 방식         | 실행 방법                          | 종료 스크립트 실행       | 소요 시간 | 상태 변화            |
|---------------|--------------------------------|------------------|-------|------------------|
| 재설정 (Reset)   | 콘솔, gcloud, API, OS            | 없음 (강제 리셋)       | 약 0초  | 실행 중 → 실행 중      |
| 시작 (Start)    | 콘솔, gcloud, API                | 없음               | 약 0초  | 종료됨 → 실행 중       |
| 재부팅 (Reboot)  | OS: <code>sudo reboot</code>   | 정상 실행            | 약 90초 | 실행 중 → 실행 중      |
| 중지 (Stop)     | 콘솔, gcloud, API                | ACPI 90초 대기 후 실행 | 약 90초 | 실행 중 → 종료됨       |
| 종료 (Shutdown) | OS: <code>sudo shutdown</code> | 정상 실행            | 약 90초 | 실행 중 → 종료됨       |
| 삭제 (Delete)   | 콘솔, gcloud, API                | ACPI 90초 대기 후 실행 | 약 90초 | 실행 중 → N/A (삭제됨) |
| 선점 종료         | 자동 (Spot/Preemptible)          | ACPI 30초 경고 후 실행 | 약 30초 | 실행 중 → 종료됨       |

## 가용성 정책 (Availability Policies) 및 유지보수 설정

### 자동으로 다시 시작 (Automatic Restart)

- 비정상 시스템 다운 또는 호스트 이벤트 시 **자동으로 VM 인스턴스 재부팅 복구**
- 사용자에게 의한 직접 종료나 Spot VM 선점 종료 시에는 적용되지 않음

### 호스트 유지보수 시 (On Host Maintenance)

- 물리 하드웨어 정기 점검 발생 시 동작 방식을 1:1 결정 (SDK/API 예약 옵션)
- **라이브 마이그레이션 (Live Migration)**이 기본값으로 자동 지정됨

### 무중단 라이브 마이그레이션 (Live Migration)

- 호스트 점검 도중 VM 인스턴스가 **서비스 중단이나 재부팅 없이 다른 정상 하드웨어로 자동 실시간 이주**
- 인스턴스 메타데이터(Metadata)에 라이브 마이그레이션 발생 내역이 자동으로 기록 및 노출됨

## Google Cloud OS 패치 관리 (OS Patch Management)

- 인프라 관리의 핵심 요소:
  - Google Cloud OS Config 서비스를 통해 여러 VM의 OS 패치를 쉽게 중앙 통합 관리
- 주요 핵심 가치:
  - 인프라 운영 환경을 항상 최신 상태로 유지
  - 보안 취약점(Vulnerability) 노출 위험 대폭 감소
- OS 패치 관리 주요 기능:
  - 패치 규정 준수 보고 (Compliance Reporting)
  - 자동 패치 배포 (Patch Deployment)



OS Patch Management

## OS 패치 관리를 위한 유연한 실행 작업 및 정책

### ✅ 패치 승인 (Patch Approval)

검증된 보안 패치 및 업데이트만 선별하여 안전하게 배포 승인 규칙 생성

### 🕒 유연한 예약 설정 (Schedules)

서비스 영향을 최소화하기 위해 주말/야간 등 원하는 정기 점검 유지보수 시간대 지정

### ⚙️ 고급 패치 구성 설정 적용

패치 전/후 실행할 커스텀 스크립트 지정 및 OS 자동 재부팅 세부 정책 구성

### 🌐 중앙 위치 통합 제어

Google Cloud 콘솔 한 곳에서 프로젝트 내 수백 대 VM의 패치 작업 일괄 관리

## 중지(종료)된 VM에 대한 과금 리소스 (Billing for Stopped VMs)

### ✗ 과금되지 않는 리소스 (요금 0원)

- CPU 연산 리소스 (vCPU)
- RAM 시스템 메모리

\* VM이 중지(STOPPED/TERMINATED) 상태인 동안에는 CPU와 RAM에 대한 비용이 전혀 청구되지 않습니다.

### 💰 계속 과금되는 리소스 (요금 발생)

- 연결된 디스크 (Persistent Disk / Local SSD)
- 예약된 고정 외부 IP 주소 (Reserved Static IP)

\* 디스크에 저장된 데이터 용량과 예약된 IP 주소 점유에 대한 요금은 지속적으로 유지됩니다.

## 중지(종료)된 VM에서 지원되는 설정 변경 작업

### 사양 & 디스크 수정

- 머신 유형 변경: vCPU 및 RAM 메모리 사양 조정
- 연결된 디스크 추가/삭제 및 자동 삭제 설정 변경

### 네트워크 & 메타데이터

- 인스턴스 네트워크 태그 수정
- 커스텀 및 프로젝트 전체 메타데이터 수정

### IP & 가용성 정책

- 고정 IP 삭제 또는 새로 설정
- 가용성 정책(자동 재시작 등) 수정

### 변경 불가능한 항목

- 중지된 VM의 OS 이미지는 변경 불가능  
(다른 OS 이미지 적용 필요 시 신규 인스턴스 생성 필수)

## 실습 소개: Compute Engine 가상 머신 만들기 (Lab Preview)



### 실습 목표 및 주요 수행 과제

- **Google Cloud 콘솔 및 gcloud CLI 활용:** Compute Engine VM 인스턴스를 직접 생성
- **커스텀 인프라 구성:** vCPU/메모리 머신 타입, 부팅 디스크 및 Nginx 웹 서버 설치
- **SSH 접속 & 네트워크 테스트:** 브라우저 SSH 접속을 통한 웹 서버 구동 및 외부 IP 수신 확인

SECTION 02


# 02

## 가상 머신 접근 및 수명주기

Compute Engine VM 접속 방법(SSH/RDP), IAM 역할 제어, 인스턴스 템플릿, 커스텀 머신 사양 조립 및  
VM 수명주기 완벽 가이드

## Compute Engine 가상 머신 생성 방법 (Creating VMs)


- **Google Cloud 콘솔 웹 UI:** 직관적인 브라우저 인터페이스를 통한 VM 조립
- **gcloud 명령어 CLI:** `gcloud compute instances create` 터미널 명령어 자동화
- **RESTful API 및 Terraform:** IaC(Infrastructure as Code) 자동화 배포 지원
- **인스턴스 템플릿 (Instance Templates):** 동일 사양의 VM을 대량 복제 생성하는 청사진



VM Provisioning

## 인스턴스 템플릿 (Instance Templates)


- VM 생성을 위한 글로벌 재사용 청사진:
  - 머신 유형, 부팅 디스크 이미지, 네트워크 태그, 메타데이터, 시작 스크립트를 한번에 정의
- 관리형 인스턴스 그룹 (MIG)의 기본 단위:
  - 오토스케일링(Autoscaling) 및 자동 복구(Autohealing)를 수행할 머신의 표준 표준 규격 제공
- 불변성 (Immutable) 원칙: 템플릿 생성 후에는 수정이 불가능하며, 업데이트 시 새 버전 템플릿을 생성



Instance Templates

## 커스텀 머신 유형 (Custom Machine Types)

- **vCPU 및 메모리 자유 맞춤 구성:**
  - 사전 정의된 머신 표준 규격 외에 워크로드 특성에 정확히 맞는 vCPU 및 RAM 비율 선택
- **비용 최적화 (Cost FinOps):**
  - 불필요하게 과도한 메모리나 CPU를 구매하지 않고 오버프로비저닝 제거
- **2026 최신 N4, C3D, E2 지원:** 커스텀 머신 사양 생성 가능



Custom VM Sizing

## 커스텀 머신 사양 조립 및 제약 법칙 (Custom Sizing Rules)

### vCPU 배치 규칙

짝수 개 단위(1개 제외, 2, 4, 8, 16, 32...)의 vCPU 코어 수 지정 가능

### vCPU당 메모리 비율 법칙

vCPU당 0.9GB에서 최대 6.5GB 사상 RAM 메모리 비율 제한 적용

### Extended Memory (확장 메모리 옵션)

표준 vCPU당 메모리 제한(6.5GB)을 초과하는 대용량 인메모리 DB 워크로드의 경우, GB당 추가 비용을 지불하고 Extended Memory를 할당하여 인스턴스 배치 가능

## gcloud CLI를 통한 인스턴스 생성 및 명령어 예시

### gcloud compute instances create 터미널 명령어

```
gcloud compute instances create my-vm-instance W  
  --zone=asia-northeast3-a W  
  --machine-type=e2-standard-2 W  
  --image-family=debian-12 W  
  --image-project=debian-cloud W  
  --tags=http-server,https-server W  
  --metadata=startup-script='#!/bin/bash apt-get update && apt-get install -y nginx'
```

## 인스턴스 메타데이터 및 시작 스크립트 (Startup Scripts)

### 메타데이터 (Metadata)

VM 내부에서 HTTP API

( `http://metadata.google.internal/computeMetadata/v1/` )로 조회 가능한 인스턴스 식별 정보 및 프로젝트 키/값 저장소

### 시작 스크립트 (Startup Script)

VM 부팅 직후 root 권한으로 자동 실행되는 Shell / PowerShell 스크립트로 소프트웨어 자동 설치 및 환경 설정 수행

## 인스턴스 종료 스크립트 (Shutdown Scripts)

### ● 종료 스크립트의 동작 메커니즘

- VM 인스턴스가 중지(Stop), 재부팅(Reboot), 삭제>Delete>되거나 Spot 선점 시 ACPI 이벤트 발생 직후 실행
- **종료 대기 시간**: 시스템이 완전 중지되기 전까지 최대 90초(Spot VM은 30초) 대기 시간 제공

### 📁 주요 활용 케이스

- 처리 중인 작업 버퍼 플러시 및 세션 데이터 안전 저장
- 로그 파일 중앙 수집 서버(Cloud Logging)로 즉시 전송
- 로드 밸런서 Target Group에서 인스턴스 Deregistration 신고

## SSH/RDP 접근 제어 및 OS Login (VM Security)

### 전통적인 SSH 키 관리

프로젝트 전체 SSH 키 또는 인스턴스별 메타데이터 SSH 공개키 등록 방식 (키 교체 관리 부담 존재)

### Google Cloud OS Login (권장)

IAM 사용자 계정 및 OAuth 2.0 기반으로 SSH 접속 권한을 중앙 통합 제어하는 보안 서비스

### OS Login 핵심 IAM 역할 권한

- `roles/compute.osLogin` : 일반 사용자 SSH 접속 권한
- `roles/compute.osAdminLogin` : sudo 루트 관리자 권한 SSH 접속

## 프로젝트 및 인스턴스 수준 SSH 키 관리 비교

| 구분        | 프로젝트 수준 SSH 메타데이터 키           | 인스턴스 수준 SSH 메타데이터 키                     |
|-----------|-------------------------------|-----------------------------------------|
| 적용 범위     | 프로젝트 내 생성되는 모든 VM 인스턴스에 일괄 적용 | 지정한 단 1대의 특정 VM 인스턴스에만 적용               |
| 우선순위 / 차단 | 인스턴스 설정에서 프로젝트 메타데이터 키 차단 가능  | 인스턴스 수준 키가 개별 등록되어 프로젝트 키보다 전용 적용       |
| 보안 권장사항   | 키 유출 위험 및 중앙 관리 어려움으로 사용 지양   | <b>OS Login 사용</b> 을 가장 적극 권장 (2026 표준) |

## Compute Engine 가상 머신 수명 주기 개요 (Lifecycle Overview)

- **프로비저닝 (PROVISIONING)**: 호스트 물리 리소스(vCPU, RAM, Disk) 할당 단계
- **스테이징 (STAGING)**: IP 주소 지정, 부팅 디스크 이미지 복사 및 OS 부팅 준비
- **실행 중 (RUNNING)**: VM이 정상 작동하며 서비스 제공 상태
- **정지됨 (SUSPENDED)**: RAM 상태를 영구 디스크에 보존하고 연산 중단
- **종료됨 (TERMINATED)**: VM이 완전히 멈춘 상태 (vCPU/RAM 비용 0원)

 VM Lifecycle Overview

**VM Lifecycle States**

## VM 생성 및 시작 상태 (PROVISIONING → STAGING → RUNNING)

### 1 PROVISIONING (프로비저닝)

물리 컴퓨팅 서버 랙에서 CPU, RAM, 네트워크 대역폭 및 디스크 자원 확보 배치

### 2 STAGING (스테이징)

VPC 사설 IP 지정, 영구 디스크 부팅 섹터 연결 및 인스턴스 OS 부팅 초기화

### 3 RUNNING (실행 중)

- OS가 정상 구동되며 사용자 요청 및 웹 서비스 수행
- API 메서드 `instances.start()` 호출로 중지(TERMINATED) 상태의 VM을 다시 RUNNING 상태로 전환 가능

## VM 일시 중지 및 재개 (instances.suspend / resume)

### ▮ Suspend (일시 중지)

- `instances.suspend()` API 호출
- VM의 **RAM 메모리 상태**를 영구 디스크로 덤프 저장한 후 연산 일시 정지
- RAM 저장용 스토리지 비용만 청구되며 CPU/RAM 요금은 즉시 중단됨

### ▶ Resume (재개)

- `instances.resume()` API 호출
- 디스크에 저장된 RAM 덤프를 복원하여 기존 작업 상태 및 실행 프로그램 그대로 빠른 재개
- 재부팅(Reboot)보다 빠른 복구 속도 제공

## VM 중지 및 삭제 (instances.stop / delete)

### □ Stop (중지)

- `instances.stop()` API 호출
- OS 종료 절차(ACPI 90초 통지)를 거쳐 `TERMINATED` 상태로 전환
- **CPU 및 RAM 과금 즉시 중지** (단, 연결된 영구 디스크 및 고정 IP 요금 지속)

### 🗑 Delete (삭제)

- `instances.delete()` API 호출
- VM 인스턴스 완전 제거 및 물리 자원 반납
- **자동 삭제(Auto-delete)** 옵션이 켜진 부팅 디스크도 함께 영구 삭제됨

## 실행 중인 VM의 상태 변경 비교표 (State Transitions)

| 작업 방식         | 실행 방법                          | 종료 스크립트 실행       | 소요 시간 | 상태 변화            |
|---------------|--------------------------------|------------------|-------|------------------|
| 재설정 (Reset)   | 콘솔, gcloud, API, OS            | 없음 (강제 리셋)       | 약 0초  | 실행 중 → 실행 중      |
| 시작 (Start)    | 콘솔, gcloud, API                | 없음               | 약 0초  | 종료됨 → 실행 중       |
| 재부팅 (Reboot)  | OS: <code>sudo reboot</code>   | 정상 실행            | 약 90초 | 실행 중 → 실행 중      |
| 중지 (Stop)     | 콘솔, gcloud, API                | ACPI 90초 대기 후 실행 | 약 90초 | 실행 중 → 종료됨       |
| 종료 (Shutdown) | OS: <code>sudo shutdown</code> | 정상 실행            | 약 90초 | 실행 중 → 종료됨       |
| 삭제 (Delete)   | 콘솔, gcloud, API                | ACPI 90초 대기 후 실행 | 약 90초 | 실행 중 → N/A (삭제됨) |
| 선점 종료         | 자동 (Spot/Preemptible)          | ACPI 30초 경고 후 실행 | 약 30초 | 실행 중 → 종료됨       |

SECTION 03

# 03

## 무중단 실시간 이동 & 가용성

물리 호스트 서버 점검 시 다운타임 없는 라이브 마이그레이션(Live Migration), 비정상 종료 시 자동 다시 시작 및 OS 패치 관리 정책 가이드

## 가용성 정책 (Availability Policies) 및 유지보수 옵션

### 자동으로 다시 시작 (Automatic Restart)

- 비정상 시스템 다운 또는 호스트 이벤트 발생 시 **자동으로 VM 인스턴스를 새로운 호스트에서 재부팅 복구**
- 사용자에 의한 직접 종료나 Spot VM 선점 종료 시에는 작동하지 않음

### 호스트 유지보수 시 (On Host Maintenance)

- 물리 하드웨어 정기 점검 시 동작 정책 지정
- **라이브 마이그레이션 (Live Migration)**이 기본값으로 적용됨

## 무중단 라이브 마이그레이션 (Live Migration) 메커니즘

- 다운타임 없는 실시간 이주:
  - 물리 서버 소프트웨어/하드웨어 정기 점검 시 VM 서비스 중단 없이 정상 서버로 이주
- 메모리 및 네트워크 연결 유지:
  - VM의 메모리 상태와 활성 TCP 연결이 그대로 보존되어 사용자는 마이그레이션 사실을 감지하지 못함
- 메타데이터 기록: 인스턴스 메타데이터 이벤트 항목에 마이그레이션 발생 내역 자동 기록

 Live Migration

**Live Migration**

## 비정상 종료 시 자동 다시 시작 (Automatic Restart)

### ⚡ 하드웨어 결함 발생 시 동작

- 물리 인프라 고장, 전원 공급 장애 또는 하이퍼바이저 래치 다운 발생 시 감지
- Google Cloud가 사용 가능한 다른 정상 물리 호스트에서 동일한 인스턴스를 **자동으로 다시 부팅 복구**

### ⚠ 예외 적용 사항

- 사용자가 직접 gcloud/콘솔로 VM을 Stop하거나 OS 내부에서 `sudo shutdown` 을 한 경우 실행 안 됨
- Spot VM / Preemptible VM 선점 종료 시에는 적용 안 됨

## 호스트 유지보수 이벤트 알림 및 제어

### 미리 알림 메타데이터 노출

라이브 마이그레이션 발생 60초 전 메타데이터 서버를 통해 애플리케이션에 이벤트 알림 전달 가능

### 마이그레이션 수동 트리거 테스트

gcloud 커맨드( `gcloud compute instances simulate-maintenance-event` )로 마이그레이션 동작 모의 테스트 가능

## Google Cloud OS 패치 관리 (OS Patch Management)

- 인프라 관리의 핵심 서비스 (OS Config):
  - Google Cloud OS Config를 통해 대규모 VM 수백 대의 OS 보안 패치 상태를 중앙 통합 관리
- 주요 핵심 효과:
  - 인프라 OS 버전을 최신으로 유지하고 제로데이 보안 취약점 노출 위험 최소화
- 핵심 패치 기능: 패치 규정 준수 보고 및 자동 패치 배포 관리



OS Patch Management

## OS 패치 승인, 예약 및 고급 패치 설정

### 패치 승인 (Patch Approval)

검증된 보안 패치 및 업데이트만 선별하여 안전하게 배포 승인 규칙 생성

### 유연한 예약 설정 (Maintenance Schedules)

서비스 영향을 최소화하기 위해 주말/야간 등 원하는 정기 점검 유지보수 시간대 지정

### 고급 패치 구성 적용

패치 전/후 실행할 커스텀 스크립트 지정 및 OS 자동 재부팅 세부 정책 구성

### 중앙 위치 통합 제어

Google Cloud 콘솔 한 곳에서 프로젝트 내 수백 대 VM의 패치 작업 일괄 관리

## 중지(종료)된 VM에 대한 과금 리소스 (Billing for Stopped VMs)

### ✗ 과금되지 않는 리소스 (요금 0원)

- CPU 연산 리소스 (vCPU)
- RAM 시스템 메모리

\* VM이 중지(STOPPED/TERMINATED) 상태인 동안에는 CPU와 RAM에 대한 비용이 전혀 청구되지 않습니다.

### 💰 계속 과금되는 리소스 (요금 발생)

- 연결된 디스크 (Persistent Disk / Local SSD)
- 예약된 고정 외부 IP 주소 (Reserved Static IP)

\* 디스크에 저장된 데이터 용량과 예약된 IP 주소 점유에 대한 요금은 지속적으로 유지됩니다.

## 중지(종료)된 VM에서 지원되는 설정 변경 작업

### 사양 & 디스크 수정

- 머신 유형 변경: vCPU 및 RAM 메모리 사양 조정
- 연결된 디스크 추가/삭제 및 자동 삭제 설정 변경

### 네트워크 & 메타데이터

- 인스턴스 네트워크 태그 수정
- 커스텀 및 프로젝트 전체 메타데이터 수정

### IP & 가용성 정책

- 고정 IP 삭제 또는 새로 설정
- 가용성 정책(자동 재시작 등) 수정

### 변경 불가능한 항목

- 중지된 VM의 OS 이미지는 변경 불가능  
(다른 OS 이미지 적용 필요 시 신규 인스턴스 생성 필수)

SECTION 04

# 04

## Compute Engine 스토리지 옵션

Persistent Disk (Standard, Balanced, SSD), 차세대 Hyperdisk, 물리 탑재 초고속 Local SSD 및  
Cloud Storage 오브젝트 스토리지 연동 종합 가이드

## 영구 디스크 (Persistent Disk - PD) 라인업

- **Standard PD (표준 영구 디스크):** 저비용 대용량 순차 I/O 및 백업 워크로드
- **Balanced PD (균형 영구 디스크 - 2026 기본값):** 가격 대비 뛰어난 IOPS 및 성능 제공
- **SSD PD (SSD 영구 디스크):** 임의 I/O 처리량이 많은 엔터프라이즈 DB 적합
- **Extreme PD:** 높은 IOPS 성능을 필요로 하는 초고성능 DB 전용 스토리지



Persistent Disk (PD)

## 차세대 Hyperdisk (Hyperdisk Extreme & Throughput)

- IOPS 및 스루풋 독립 동적 프로비저닝:
  - 디스크 용량을 늘리지 않고도 필요한 IOPS와 MB/s 처리량만 개별 동적 확장
- 2026 차세대 블록 스토리지 아키텍처:
  - Hyperdisk Extreme: 최대 500,000 IOPS 미션 크리티컬 워크로드 지원
  - Hyperdisk Throughput: 대규모 빅데이터 분석 및 인메모리 수집 처리



Hyperdisk (2026)

## VM에 물리적으로 연결되는 로컬 SSD 디스크 (Local SSD)


- 영구 디스크보다 더 높은 IOPS, 더 짧은 지연 시간, 더 많은 처리량
- 375GB 디스크 최대 24개, 인스턴스당 총 9TB (2026 C3/C4 1.5TB 블록 지원)
- 재설정(Reset) 후에도 데이터 유지 (단, VM 중지나 종료 후에는 유지되지 않음)
- VM 특징: 다른 VM에 다시 연결할 수 없음 (Ephemeral Cache)



Local SSD (NVMe)

## Cloud Storage 오브젝트 스토리지 연동 (gcsfuse)

- 비정형 데이터 및 오브젝트 저장소 연동:
  - 이미지, 비디오, 대규모 데이터셋을 위한 무제한 Cloud Storage 버킷 연결
- Cloud Storage FUSE (gcsfuse):
  - Cloud Storage 버킷을 VM 인스턴스의 로컬 파일 시스템 마운트 디렉토리처럼 투명하게 마운트하여 사용



Cloud Storage (GCS)

## Compute Engine 디스크 스토리지 종합 비교표 (Storage Comparison)

| 스토리지 유형     | 주요 특징          | 최대 IOPS            | 데이터 영속성          | 추천 유즈케이스          |
|-------------|----------------|--------------------|------------------|-------------------|
| Standard PD | 저비용 HDD 블록 디스크 | 수천 IOPS 수준         | 영속성 보장 (독립 스토리지) | 대용량 백업 및 순차 로그    |
| Balanced PD | 가격 대비 성능 최적 균형 | 중상위 IOPS           | 영속성 보장 (독립 스토리지) | 일반 웹 앱, 개발/테스트 DB |
| SSD PD      | 초고속 NVMe 기반 PD | 고성능 IOPS (최대 10만+) | 영속성 보장 (독립 스토리지) | 엔터프라이즈 RDBMS 및 DB |
| Local SSD   | 물리 서버 랙 직접 연결  | 최상위 IOPS (수백만+)    | 휘발성 (중지/종료 시 삭제) | 초고속 임시 캐시 및 파티션   |